

TRABAJO PRÁCTICO

Asignatura: Probabilidad y Estadística

Trabajo Práctico Grupal: Variables Aleatorias

Integrantes: Nicolas Bacalini, Travesani Benicio

Paso I. Selección de Datos, Definiciones y Variables

Descripción del Dataset

- **Fuente:** Kaggle — Cyber Security Attacks (teamincrito).
- **Tamaño:** 40000 registros válidos y 25 columnas.
- **Contexto:** Registros de tráfico de red con detección de ataques (DDoS, Malware, Intrusión).

Marco Teórico General

- **Variable Aleatoria:** Es una función que asigna un valor numérico a cada resultado posible de un experimento aleatorio.

Definición de Variables del Estudio

- **Variable Aleatoria Discreta (X):** Se define X como la cantidad de ataques registrados por hora en la red. Es discreta porque los ataques son eventos contables que toman valores enteros finitos.
- **Variable Aleatoria Continua (Y):** Se define Y como el tamaño en bytes de cada paquete de red (Packet Length). Es continua porque resulta de una medición y puede tomar cualquier valor real dentro de un intervalo.



Paso II. Variable Discreta (X): Análisis Completo

Análisis de la Muestra Tras agrupar los datos por hora y rellenar los espacios temporales sin actividad, se analizaron un total de **33116** horas.

Recorrido de X Los ataques que se pueden recibir en una hora van de **0** a **7**.

Tabla de Probabilidad Puntual y Función de Distribución Acumulada (FDA) La siguiente tabla detalla la probabilidad exacta de que ocurran x ataques en una hora, y la probabilidad acumulada de sufrir x ataques o menos:

Cantidad de Ataques (x)	Probabilidad $p_X(x)$	Acumulada $F_X(x)$
0	0.299946	0.299946
1	0.357471	0.657416
2	0.220498	0.877914
3	0.088175	0.966089
4	0.026483	0.992572
5	0.005919	0.998490
6	0.001208	0.999698
7	0.000302	1.000000



Comparación Notable: notamos que en la gráfica, entre mayor sea la cantidad de ataques menor es el salto que realiza la probabilidad acumulada, dado que entre más ataques sufra el servidor, más se acerca a la probabilidad acumulada.

Definiciones Estadísticas y Parámetros

- **Esperanza $E[X]$:** Representa el valor promedio esperado a largo plazo. En nuestra red, el cálculo arroja $E[X] = 1.2079$ ataques/hora.
- **Varianza $Var(X)$:** Mide la dispersión de los datos respecto a la esperanza. El resultado es $Var(X) = 1.2040$.

Comparación Notable y Modelo Teórico Observando el diagrama de barras de la función de probabilidad puntual, notamos que la gráfica inicia cerca de un valor máximo y decae suavemente hacia la derecha dejando una cola larga. Este comportamiento visual sugiere una **Distribución de Poisson**, ideal para modelar eventos aleatorios en un intervalo de tiempo continuo. Matemáticamente, esta asunción empírica se confirma al contrastar nuestros parámetros: la Esperanza (1.2079) y la Varianza (1.2040) son prácticamente idénticas, cumpliendo con la propiedad fundamental de este modelo estadístico.

Paso III. Variable Continua (Y): Trayecto Guiado

Fase 1: Histograma y Regla de Sturges Para analizar la variable continua Y, agrupamos los datos aplicando la Regla de Sturges para hallar el número óptimo de intervalos (k) considerando $n = 40000$:

$$k = \lceil 1 + 3.322 \cdot \log_{10}(n) \rceil$$


$$k = \lceil 1 + 3.322 \cdot \log_{10}(40000) \rceil$$

$$k = \lceil 1 + 3.322 \cdot 4.602 \rceil$$

$$k = \lceil 16.28 \rceil$$

$$k = 17$$

Se agrupan los datos en **17** intervalos para construir el histograma de frecuencias relativas.



Fase 2: Identificación Visual y Teórica Como se puede ver en el gráfico, el mismo posee barras de alturas similares a lo largo de todo el recorrido. Esto nos permite identificar a la variable como candidata a una **Distribución Uniforme Continua**, donde todos los valores dentro del rango tienen la misma probabilidad de ocurrencia.

Fase 3: Parametrización Extraemos los valores extremos reales de la variable Y desde el dataset:

- **Mínimo (a):** 64 bytes
- **Máximo (b):** 1500 bytes

Con estos parámetros, definimos la Función de Densidad de Probabilidad $f_Y(y)$ constante:

$$f_Y(y) = \begin{cases} \frac{1}{1436} & \text{si } 64 \leq y \leq 1500 \\ 0 & \text{en cualquier otro caso} \end{cases}$$

Fase 4: Verificación de Normalización y FDA Para validar la legitimidad del modelo, demostramos que la integral definida de la función de densidad sobre todo su dominio es exactamente igual a 1 (100% del espacio muestral):

$$\int_{64}^{1500} \frac{1}{1436} dy = \frac{1}{1436} \left[y \right]_{64}^{1500} = \frac{1}{1436} \cdot (1500 - 64) = \frac{1}{1436} \cdot 1436 = 1$$

A partir de la función de densidad, construimos la Función de Distribución Acumulada $F_Y(y)$:

$$F_Y(y) = \begin{cases} 0 & \text{si } y < 64 \\ \frac{y-64}{1436} & \text{si } 64 \leq y \leq 1500 \\ 1 & \text{si } y > 1500 \end{cases}$$

Finalmente, extraemos los estadísticos muestrales de los **40000** registros de red para los cálculos finales:

- **Densidad teórica:** 0.000696
- **Media muestral ($\bar{y}$):** 781.45 bytes
- **Desviación estándar muestral (s):** 416.04 bytes

Paso IV. Interpretación de Resultados

a) Variable Continua Y Según el modelo Uniforme Continuo ajustado, se espera que el **78.93%** de las observaciones se encuentren por debajo del umbral definido por la media muestral más una desviación estándar $F_Y(\bar{y} + s) = 1197.49$ bytes.

b) Variable Discreta X (Umbral operativo k=3) Al definir un umbral de alerta de k=3 ataques por hora, la función de distribución acumulada nos indica que la probabilidad es de 0.9661. En el contexto de la administración de nuestra red, esto significa que el volumen de ataques se mantendrá en 3 o menos durante el **96.61%** del tiempo. Establecer un límite de seguridad al superar este umbral resulta operativamente eficiente, ya que el equipo técnico solo será alertado en el **3.39%** de las horas más críticas, evitando la saturación por falsos positivos.

c) Reflexión General Los modelos representan adecuadamente la tendencia general del tráfico de red. El modelo de Poisson se ajusta de forma precisa a la cantidad de ataques, evidenciado por la notoria similitud matemática entre la esperanza y la varianza empírica. Sin embargo, la distribución Uniforme presenta ciertas limitaciones prácticas para modelar la longitud de paquetes: el modelo teórico asume una probabilidad estrictamente constante para cualquier valor dentro del rango, mientras que en la realidad tecnológica los paquetes de red tienden a agrupar su tamaño en valores estandarizados por la arquitectura subyacente (como 64, 512 o 1500 bytes).